

Proyecto Teledetección - Detección de Barcos (MASATI)

Informe Técnico de Laboratorio y Evaluación Parcial

Estudiante: Miguel Angel Calle Parra

Asignatura: Visión por Computador e Inteligencia Artificial

Institución: Politécnico Colombiano Jaime Isaza Cadavid

1. Encabezado e Introducción

El presente informe expone el desarrollo del proyecto de teledetección enfocado en la localización y segmentación precisa de embarcaciones a partir de imágenes satelitales del espectro visible. Para este estudio se empleó el dataset MASATI_v2 (MARitime SATellite Imagery), desarrollado por investigadores de la Universidad de Alicante. Este conjunto de datos abarca diversas escenas marítimas complejas caracterizadas por variaciones dinámicas en la iluminación, condiciones meteorológicas, presencia de estelas de oleaje y diferentes densidades de embarcaciones.

El objetivo central radica en evaluar y mejorar la precisión de las anotaciones originales (delimitadas manualmente mediante cajas rectangulares) mediante la integración del modelo fundacional de segmentación SAM (Segment Anything Model), desarrollado por Meta AI. Utilizando las coordenadas XML originales como pautas espaciales (prompts), se implementó una pipeline de refinamiento automático orientada a aislar los píxeles exactos del casco de cada navío. A continuación, se detallan los resultados obtenidos en cada uno de los retos planteados en la guía de práctica.

2. Reto 1: Exploración del Dataset MASATI

2.1. Procesamiento y Visualización de Anotaciones Manuales

Se implementó un script de lectura y parseo de las etiquetas guardadas en formato XML (Pascal VOC). El programa selecciona de forma aleatoria imágenes de todas las carpetas, y las que tengan un label asociado, se dibuja sobre la imagen original el recuadro (bounding box) delimitado por los anotadores humanos mediante líneas de color rojo.




Figura 1: Categoría: coast_ship — Archivo: x0774.png

Aunque en la mayoría de las imágenes el recuadro delimitador (bounding box) parece estar ajustado correctamente debido al reducido tamaño de las embarcaciones, un análisis más detallado revela imprecisiones en las anotaciones: en algunas ocasiones la etiqueta abarca más espacio del necesario y, en otras, deja secciones del barco fuera del límite marcado.



Figura 2: Categoría: ship — Archivo: s0055.png



Figura 3: Categoría: ship — Archivo: s0269.png




Figura 4: Categoría: coast_ship — Archivo: x0536.png

Debido a la dificultad para distinguir las embarcaciones del oleaje en ciertas imágenes, la delimitación mediante el bounding box depende del criterio del anotador humano.

3. Reto 2: Segmentación Automática con SAM

Para solucionar la holgura de las etiquetas manuales, se integró el modelo pre entrenado SAM. El procedimiento consistió en extraer las coordenadas límite de la anotación humana en el archivo .xml original y pasarlas al predictor como un bounding box prompt. De esta forma, SAM concentra la atención dentro de la región especificada y genera una máscara binaria a nivel de píxel que delimita la forma geométrica exacta del objeto.

Máscara Binaria SAM - x0056.png



Figura 5: Máscara Binaria SAM - x0056.png

A partir de la máscara binaria resultante, se calcularon automáticamente las nuevas coordenadas mínimas y máximas (x_{min}^{SAM} , y_{min}^{SAM} , x_{max}^{SAM} , y_{max}^{SAM}) para reconstruir un recuadro perfectamente ajustado.

Resultado SAM - x0056.png




Figura 6: Imagen a color con el nuevo bounding box ajustado a partir de la máscara binaria de SAM.

3.1. Comportamiento del Modelo y Estructuración de Archivos

El modelo SAM demostró una elevada capacidad para distinguir la reflectancia metálica del casco frente a los tonos cambiantes del agua y la turbulencia de la espuma. La pipeline procesó exitosamente el conjunto de imágenes, generando automáticamente los nuevos archivos de anotación en formato XML y almacenándolos en una estructura con el sufijo _SAM, preservando la integridad del conjunto de datos original.

4. Reto 3: Comparación Humano vs. IA

4.1. Evidencia Visual Comparativa

Para analizar el grado de refinamiento alcanzado, se generaron superposiciones gráficas en la carpeta resultados_IoU. En estas representaciones, el recuadro rojo corresponde a la anotación humana original y el recuadro verde corresponde al límite re-calculado por SAM.



Figura 7: Imagen: y0017.png — IoU: 0.47, 0.64, 0.58, 0.29, 0.61, 0.52, 0.56, 0.46, 0.56, 0.30




Figura 8: Imagen: x0079.png — IoU: 0.37

4.2. Evidencia Cuantitativa (Métrica IoU)

Se calculó numéricamente la similitud entre los dos conjuntos de recuadros mediante la métrica de Intersección sobre Unión (Intersection over Union - IoU):

$$IoU = \frac{\text{Área de Intersección}}{\text{Área de Unión}} \quad (1)$$

IMAGEN	CATEGORÍA	VALOR IOU
s0874.png	ship	0.50
s0020.png	ship	0.47
s0384.png	ship	0.74
y0017.png	multi	0.47, 0.64, 0.58, 0.29, 0.61, 0.52, 0.56, 0.46, 0.56, 0.30
x0761.png	coast_ship	0.76

5. Análisis Final y Conclusiones

1. **Interpretación de los valores de IoU:** En problemas convencionales de visión por computador, un IoU bajo suele interpretarse como un fallo de detección. Sin embargo, en esta práctica un IoU en el rango de 0.30 a 0.70 evidencia una mejora sustancial en la precisión real. El valor decrece debido a que la anotación humana inicial contenía áreas masivas de agua o espuma que SAM eliminó por completo.
2. **Eliminación del ruido de fondo:** Al ceñirse estrictamente al contorno físico del navío, SAM reduce drásticamente los píxeles de agua procesados como "barco". Esto resulta fundamental para generar un dataset limpio (Ground Truth) que permita el entrenamiento posterior de arquitecturas de detección de objetos, tanto de una

etapa (como YOLO o SSD para tiempo real) como de dos etapas (como Faster R-CNN para máxima precisión en objetos pequeños), reduciendo significativamente los falsos positivos generados por el oleaje.

3. **Eficiencia en la anotación masiva:** La combinación de la anotación humana preliminar con modelos de segmentación preentrenados demuestra ser una estrategia altamente costo-eficiente, permitiendo la re-etiquetación automatizada de datasets masivos con calidad profesional.